Афина 2.0 — архитектурная спецификация 3.3

Редакция архитектуры 3.3 • документальная сборка FINAL-D1 • 07.11.2026 • Владелец решений: Андрей

Статус: FINAL-D1 — завершённый документальный выпуск по замечаниям текущего аудита; не verified runtime/deployment. Не отчёт о развёртывании и не разрешение на покупку/внешние записи.

Основа: GitHub Colibri1985/manus-west-consulting-research, каталог Athena_v3.2.&TTS, commit a6b081eaefc710e3fa8d7170876aea2bf57a74a9 («Athena, live! 4»). Конкретные source paths и Git blob SHA перечислены в Source_Manifest.json. Дубликат имени .md с пробелом не выбран как второй primary.

Нумерация и изложение консолидированы. Это полный самостоятельный текст целевой архитектуры, а не только дополнение по голосу. Остальные решения не пересогласовываются из-за добавления TTS.

Область выпуска: исправления и уточнения v3.3 без адаптации к Hermes v0.23.0. Завершение инспекции по поручению владельца не превращает NOT_TESTED в PASS. Актуальная policy — ACP-SEC-001 r2; прежние заявления о выполненных проверках сохраняются только в historical/, не являются результатом FINAL-D1.

1. Цель и границы версии

Афина — персональный помощник Андрея на базе Hermes Agent: диалог, голос, документы, поиск, память, собственное исполнение и координация команд. Площадка HostHatch/Docker. Старая установка не переносится вслепую; полезные данные и требования восстанавливаются после ревизии.

3.3 добавляет универсальный голосовой выход: сменные движки, версии голосовых профилей, правила выбора/оплаты/конфиденциальности, synthesis jobs и независимая доставка. Не меняет выбранную embedding-модель, роль Kaiten, границы команды и warehouse. Выбор CrewAI/CADTopo остаётся открыт. Новые сторонние мастерские не вводятся этой редакцией.

Термины «подписка» разделены: коммерческий тариф поставщика и подписка пользователя на уведомления. Они описаны отдельно. Honcho/Kaiten не становятся TTS движками: их данные поступают в разрешённый текст через Hermes и policy boundary.

2. Статусы, решения и фактическая готовность

[РЕШЕНИЕ] — принято Андреем. [ПРОЕКТ] — выбранная для разработки реализация, ещё не установленная. [ОТКРЫТО] — решение/проверка впереди. [ИСТОРИЯ] — старый снимок, не current VPS. [ПЕРСПЕКТИВА] — не условие первого релиза.

Доказательность: planned→designed→implemented→verified→accepted. YAML parse, HTTP200, корректный ответ LLM и end-to-end результат — разные проверки. Выпуск документов не устанавливает ПО.

Принято: own Honcho/PostgreSQL+pgvector; embeddings openai/text-embedding-3-large/OpenRouter/1536; text models Honcho через OpenRouter; nullable project и внепроектный склад; daily full image00:00 Europe/Moscow→Windows→Kingston; Kaiten как планируемая интеграция; расширяемый TTS с Edge/ElevenLabs и будущими адаптерами/собственным голосом.

Не принято автоматически: конкретные text models/тариф ElevenLabs, Fish model/voice, собственный TTS engine/GPU, точное число containers, retention/RPO/RTO. Исходные budgets: infrastructure $50–60/month, platforms/subscriptions $100–150/month совокупно, не выделенный весь бюджет TTS.

3. Функциональные контуры

A. Личная Афина: text/voice, approved tools, документы/архивы, память, результаты. Собственные способности не исчезают при добавлении команды.

B. Мастерская/команды: роли, handoff, attempts, проверки, budget, owner acceptance. Целевая команда не подменяется одним CLI.

C. Интеграции: Kaiten/Git/knowledge и другие отдельно разрешённые сервисы, с собственными credential boundaries.

D. Эксплуатация: provisioning/network/secrets/backup/restore/monitoring. Агент не администратор VPS.

TTS — функция доставки ответа A, а не команда B и не memory pipeline. Отказ TTS/Kaiten не должен блокировать обычное общение и сохранение локального результата. Если без обязательного источника задача невозможна, она явно BLOCKED.

Frigga/Saga/Mimir/Heimdall и dashboardv4 остаются отдельными перспективами, не готовыми ролями первого релиза. Финансовая команда допустима с собственными источниками/методологией и человеческим утверждением, без автоматических платежей.

4. Компоненты и предварительное размещение

|Компонент|Функция|Граница|

|---|---|---|

|athena-runtime|Hermes/gateway/dashboard по pinned release|Один active profile home, не raw DB Honcho|

|athena-executor|Личные tools/documents/code|Назначенные inputs RO, job RW|

|team-control|Task API/coordinator/adapters|Trusted grants, ledger, budget|

|project-db|Операционное состояние|Не второй native Hermes state|

|honcho-api|Приём/recall memory|Scoped bearer/private API|

|honcho-deriver|Фоновая обработка|Не process внутри main LLM|

|honcho-db|PostgreSQL+pgvector|Dedicated persistent FS|

|honcho-redis|Cache/AOF по release|Не default source of truth|

|Kaiten adapter|Read/approved writes/sync|Token только adapter|

|Voice controller/projector|Выбор profile, speech text, policy/budget/jobs|Внутри trusted runtime/integration boundary сначала|

|TTS adapter|Native Edge/custom command/plugin|Минимальный env/text, no raw task context|

|Catalog/publisher|Artifact IDs/versions/ACL/publish|Independent of Team DB|

Исходные восемь постоянных сервисов: Core 2 + Honcho 4 + Team 2, без Catalog. Полный deployment-кандидат: Core 2 + Honcho 4 + Data/Catalog 1 + Team 2 = 9. Workers, proxy и возможный own TTS endpoint вне этого счёта. Это целевая ведомость, не факт установки и не требование одновременного запуска. Health & Fitness в эти девять не входит. TTS не требует нового постоянного контейнера автоматически. Own TTS endpoint может быть добавлен позднее отдельным ограниченным сервисом/машиной, ресурсы пока не выбраны. Native subagents Hermes не тождественны worker containers. terminal.backend=docker не равно подключённый заранее executor.

Отдельные Compose-проекты core/honcho/data/team; data и team — последующие проектные контуры, точечные API networks; existing VPN и один Caddy ИЛИ Nginx. Никаких privileged/docker.sock/general admin shell для агентов. Непривилегированные UID/GID/read-only root/cap_drop подтверждать совместимостью образа.

5. Сквозная архитектура данных

```mermaid
flowchart TB
U["Андрей / Telegram / dashboard"] --> H["Hermes / identity + policy"]
H --> EX["Личный executor"]
H --> TC["Team Control / role workflows"]
H --> KB["Kaiten adapter / allowed card snapshots"]
KB <--> K["External Kaiten / business tasks"]
H --> HM["Honcho scoped recall/single sender"]
HM --> HD[("Own Honcho PostgreSQL + pgvector")]
D["Deriver"] --> HD
D --> OR["OpenRouter embeddings1536 + text models"]
EX --> CAT["Warehouse + catalog / revisions ACL"]
TC --> CAT
CAT --> R["Checks/evidence/result"]
R --> H
H --> MR["Canonical message revision"]
MR --> TEXT["Text delivery"]
TEXT --> U
MR --> PROJ["Speech projection / privacy and length policy"]
PROJ --> V["Voice profile snapshot + billing gate"]
V --> TTS["Edge / ElevenLabs-OpenRouter / future adapters"]
TTS --> AUDIO["Decode/normalize audio + protected artifact"]
AUDIO --> DEL["Delivery service / Telegram voice or player"]
DEL --> U
```

Стрелки — interfaces/data flow, не общий filesystem mount. Нельзя направить Honcho conclusions или Kaiten event напрямую в paid synthesis до authorisation/projection. Внешний TTS получает только одобренный speech_text, не весь prompt/память/credentials.

6. Источники истины и идентичность

|Данные|Primary|

|---|---|

|Native sessions/history/auth|Hermes home/state.db/native stores|

|Краткая память|Native MEMORY/USER files согласно release|

|Долговременный контекст|Own Honcho DB/API|

|Явные знания/решения|Selected primary Obsidian/Wiki + trusted Decisions|

|Business card title/due/assignees/location|Kaiten|

|TaskRevision/run/stage/attempt/checks|Internal ledger|

|Файлы|Warehouse payload + catalog metadata|

|Правила/approvals|Trusted registry|

|Speech input|Canonical MessageRevision + versioned SpeechProjection|

|Выбранный голос|VoiceSelection→immutable VoiceProfileRevision|

|Фактический звук|AudioArtifact manifest/hash/codec|

|Оплата|Billing account/reservations/settled provider usage|

Principal_id/channel binding проверены trusted ingress. Scope=environment/privacy_domain/project optional. Session ID, board URL и client header не являются правом доступа. Work/personal изоляция включает native memory и voice cache, не только Honcho sessions. Один writer home, либо поддерживаемая нативная concurrency authority, не независимые процессы в одном profile.

Kaiten hosted data не становится локальной DB. Local cache не полный backup внешней системы. Нативные схемы Hermes/Honcho/Kaiten руками не модифицируются ради новых logical entities.

7. Основная и вспомогательные модели

Main Hermes LLM/provider остаётся открытым выбором. Text models Honcho отдельно. Командные роли имеют approved model IDs/tool/data classes/context/cost/escalation/fallback/timeouts. Новая модель не получает больше прав. Подписка не universal API endpoint.

Requested model и actual runtime/provider различаются: учитывать фактические usage/цену. Auxiliary compression/title/audio-tags отдельные вызовы и расходы. Hidden rewrite для эмоций не включать без source mapping и policy: она не должна менять цифры/смысл.

Embeddings закрыты решением: OpenAI Text Embedding3Large/OpenRouter/1536. No vendor fallback, even same dimension. Новый embedding engine требует нового пространства/миграции. TTS voice model не замена reasoning model и не часть vector search.

Ближайший этап по ACP r2: фиксированные назначения моделей по функциям. Ролевые model policies — заранее заданные назначения, не автоматический выбор модели по сложности/роли. Дополнительный model gateway, Little LLM и draft отложены. Native Hermes session gateway не равен отложенному LLM gateway.

8. Память Honcho

Self-hosted API/Deriver/PostgreSQL+pgvector/Redis. Один active external provider в Hermes, plugin совместим с pinned release. Accepted message не derived/recall-ready. Контекст ограничен по tokens/scope, provenance/freshness, contradictions не превращаются в approved rules.

Один sender/native sync authority; outbox-gap решать в том же пути, не двойной отправкой. UNKNOWN reconcile до повторного send. Corrections/tombstones/cache invalidation учитывают источники и повторное выведение. Secret scrub не complete DLP. Privatekeys/tool logs не отправляются.

Own DB не local inference: разрешённые texts уходят OpenRouter/provider. Actual single+batch embedding output1536 подтверждается в real Honcho client. Outage: optional memory→explicit degraded; required memory→blocked. Approved decision читать из trusted record, не stale recall.

TTS не пишет output audio в Honcho по умолчанию. Сохраняется один canonical conversation turn; spoken transcript/projection refs — связь, не второй дублирующий turn. Voice mood не считается психологическим фактом о пользователе. Любая preference, извлечённая из речи, проходит общую memory policy.

Exclusions по ACP r2: secrets, no-memory/no-save в заданном охвате, local-only, отсутствие права передачи и служебные dumps не отправляются Honcho. Не компенсировать исключение записью в MEMORY.md/skills/notes. «Не запоминать» не равно отсутствию native history; «не сохранять вообще» требует отдельной проверенной поддержки всех путей. До неё такой режим не обещается.

9. Kaiten: задачи и синхронизация

Статус integration planned, не recovered working connector. Adapter хранит connection/scope bindings/card refs/cursors/snapshots/operations/conflicts отдельно от native stores. Credentials в secretrefs. REST/read pagination первой стадией, webhook optional later.

CardTaskLink many-to-many с явно определённым primary publishing target. CardSnapshot immutable→proposed TaskRevision. Remote description/comment как data не trusted instruction, card move не release approval. Не every card=autoexecution и не каждый attempt новая card.

Field authority: Kaiten business fields; ledger attempts/checks/cost. Update reread/base-diff/patch owned fields; human edit conflict не last-writer-wins. Remote optimistic concurrency/idempotency только если проверены endpoint guarantees. POST timeout→UNKNOWN→reconcile, no blind duplicate create/comment.

Получение boardmetadata не даёт все cards, использовать documented paginated cards query до complete scan. Missing on incomplete page не deletion. Webhooks не trusted commands; verify supported source authentication, reread authenticated REST, dedup по доступным IDs/fingerprint, prevent echo loop.

TTS результата не добавляет audio attachment/comment в Kaiten автоматически. Это отдельный publish operation с data/access/approval policy. Public share/private VPS path не создаются как «готовая ссылка» без согласованной доставки.

10. Warehouse, lifecycle и роли исполнения

Категории: intake, standalone, one-off, library, projects, conversation-media. Project может отсутствовать. Пользовательские административные документы отделены от runbooks, deployment, governance и secrets. ArtifactRevision неизменяема; hash и provenance вычисляются при публикации. Ссылки из задач не создают независимые редактируемые копии.

Маршрутизация выполняется при поступлении, архивирование — отдельный статус по основанию. Other не означает бесконтрольную папку «Разное». Подозрительные файлы ограничиваются, зашифрованные не считаются обработанными, дубликаты сохраняют сведения о поступлении. Внешнесвязанные Excel-комплекты не переименовываются автоматически. Hold запрещает удаление. Work cleanup разрешён только после terminal state, публикации нужных результатов и проверки leases/refs по утверждённой retention policy. Числовые сроки пока открыты.

Skill — процедура; tool — действие; role — ответственность; memory — контекст. Реестр фиксирует версии, source/hash, зависимости, scopes, model policy и тесты. Массовая установка packs и самостоятельное изменение approved skills без policy не допускаются.

Каталог ролей: PM, BA, SA, Architect, 1C Analyst по scope, UX, Developer, Data Engineer, QA, Reviewer, Git Manager, DevOps/Release, Coordinator. Software, analytical и finance — разные маршруты. Handoff содержит TaskRevision, attempt, bundle, snapshots, criteria, checks, ограничения и следующего владельца. Durable intent, receiver receipt и execution — разные события. Stale fencing/revision отклоняются; повторы и стоимость ограничены; неизвестный внешний эффект требует reconcile. Независимый QA, приёмка владельцем и release approval разделены.

11. Документы, STT, TTS и realtime

Поддержка Office/PDF/CSV/Markdown и архивов подтверждается сквозными сценариями. ZIP/RAR/7z требуют квот, проверки путей и symlinks, запрета auto-execute. Сложные Excel/PQ/Pivot/VBA и внешние связи не пересохраняются сторонним движком без доказанной сохранности. Native Windows/Excel runner — отдельное решение; строка формулы не доказывает вычисленное значение.

STT: audio → transcript. TTS: text → audio. Transport: доставка. Realtime: микрофон, воспроизведение, прерывание и жизненный цикл потока. Редакция3.3 утверждает сменный TTS, а не автоматически новую STT или full-duplex Mini App. Существующий STT не меняется ради выбора голоса.

Пользовательский текст остаётся доступным при ошибке синтеза. Telegram voice не гарантирует autoplay. Непрерывный разговор требует отдельного feasibility test, без обязательного перехода в другой messenger.

12. Универсальная TTS-подсистема

Общий контракт: разрешённый текст + snapshot профиля + формат результата → audio result или типизированная ошибка. Backend adapters: встроенный Edge, ElevenLabs через OpenRouter, возможный direct ElevenLabs, будущий Fish и собственный endpoint. Добавление движка не переписывает агентский turn handling и доставку.

VoiceEngineRevision описывает transport/model/capabilities/auth routing. VoiceIdentityRevision — узнаваемый голос, voice ID и материалы. VoiceProfileRevision фиксирует engine + identity + язык + style/format/policy/billing. Один движок может иметь несколько профилей; переносимость одного голоса между движками не предполагается.

Capabilities задаются отдельно: whole_file, stream_pcm, list_voices, instructions, speed, cloning, locality. Неподдерживаемые параметры отклоняются либо соответствующая настройка отключена; нельзя молча игнорировать выбор пользователя. Fallback не расширяет передачу данных и не меняет голос неожиданно.

Первый этап — whole-file reply. Реальное streaming позже требует plugin interface, ограниченного PCM buffer и точных sample_rate/channels/encoding/timebase. HTTP byte stream не равнозначен непрерывному разговору. Command idle timeout не заменяет общий deadline job.

13. Голосовые профили и переключение

|Профиль|Backend|Статус активации|

|---|---|---|

|svetlana|Edge online, ru-RU-SvetlanaNeural|Начальная конфигурация; работоспособность проверяется на сервере|

|athena_natural|ElevenLabs через OpenRouter; elevenlabs/eleven-v4-turbo — стартовый кандидат|Нужны выбранный voice ID, доступ аккаунта, бюджет и тест|

|athena_elevenlabs_direct|Прямой ElevenLabs API|Зарезервирован, тариф не выбран|

|athena_fish|Отдельный согласованный Fish route|Модель и голос пока не выбраны|

|athena_own|Собственный локальный/серверный движок|Архитектурная возможность, ресурсы открыты|

Контроллер проверяет права инициатора, expected_version, готовность профиля, capabilities, права на голос и бюджет. Затем атомарно создаёт новую ревизию выбора. Каждый ответ фиксирует неизменяемый snapshot профиля до синтеза. Уже выполняющийся ответ не меняет голос посередине фразы или между чанками.

Первый scope выбора — профиль Hermes. Переключение на уровне чата возможно только после реализации отдельного mapping и передачи выбора в каждый запрос. Нельзя обслуживать параллельные чаты конкурентным редактированием одного глобального config.yaml.

Желаемый UI — переключатель готовых профилей. На первом этапе допускается изменение tts.provider с поддерживаемым reload/restart и readback. Горячее переключение не объявляется существующей функцией. Speech off — режим вывода, а не несуществующий native provider:none. При неготовом платном профиле исходный выбор не меняется молча.

Selection scope hermes_profile реализуется trusted mapping principal/privacy scope → native profile binding. До появления per-chat mapping конкурирующее переключение чатов через общий config запрещено. Список GET profiles конечный в этой редакции, возвращается целиком; при введении pagination потребуется согласованная версия контракта.

14. Собственный голос Афины

Архитектура допускает референсные записи, расшифровки, speaker prompts/embeddings, адаптеры и специально подготовленные веса модели. Для каждого материала фиксируются источник, право использования, согласие при необходимости, лицензия, hash и версия. Право воспроизводить запись не означает право обучать на ней другую модель или экспортировать сервисный voice clone.

Создание собственного голоса не входит автоматически в первый этап. Движок, метод подготовки, исполнитель, вычислительная среда и ресурсы выбираются отдельно. Возможные источники — собственный voice design в разрешённой системе либо записи диктора с необходимыми правами.

Результаты ElevenLabs не используются для подготовки другой AI-модели в обход условий поставщика. Не предполагается, что платная подписка разрешает такое использование. При необходимости отдельное разрешение подтверждается до обработки.

Идентичность голоса и манера речи разделены. Один нейтральный референс не гарантирует все эмоции; перенос между движками не обещает идентичного звучания. Возможности задаются capability-контрактом.

Создание/дообучение и ежедневный inference требуют разных ресурсов. Голосовые активы хранятся в постоянном хранилище с backup, а не в work/cache. Отзыв права блокирует новые задания и повторное воспроизведение из кеша; судьба истории и резервных копий определяется отдельной политикой.

15. Коммерческие подписки, биллинг и разрешение затрат

Коммерческий тариф и голосовой профиль — разные сущности. Используются BillingAccount, EntitlementRevision, RateCardRevision, BudgetReservation и SpeechUsage. Маршрут профиля определяет, какой аккаунт действительно оплачивает запрос.

|Маршрут|Источник оплаты|Credentials|Не предполагается|

|---|---|---|---|

|Edge|Без API-платы в исходной схеме|API-ключ не нужен|Офлайн-работа, бессрочный SLA или гарантированный безлимит|

|OpenRouter → ElevenLabs|Баланс и фактическое использование OpenRouter|OpenRouter TTS key|Прямая подписка ElevenLabs не пополняет OpenRouter|

|Прямой ElevenLabs|Действующий план/PAYG/квоты аккаунта|ElevenLabs key|OpenRouter key не заменяет его|

|BYOK через маршрутизатор|Условия конкретного поддерживаемого BYOK-маршрута|Согласованные credentials|Отсутствие комиссий и двойного учёта без проверки|

|Fish|Выбранный прямой или посреднический маршрут|Собственный credential ref|Автоматически выбранная бесплатная модель|

|Собственный движок|Вычисления, хостинг, лицензии|Локальный scoped auth при необходимости|Нулевая стоимость или достаточность текущего VPS|

Цены хранятся в versioned RateCard, а не зашиваются в архитектуру. Единицы — символы, токены, секунды или кредиты — определяются фактическим маршрутом. Валюта, налоги, комиссии и конвертация кредитов учитываются

явно. Квота тарифа и API rate limit не смешиваются.

До dispatch резервируется верхняя расчётная стоимость с учётом чанков и применимых тарифов. Лимиты периода и параллельности проверяются атомарно. Это локальный admission guard, не гарантия мгновенного внешнего списания или остановки начатого запроса. Provider-side spend limits используются, если поддерживаются.

Если платный бюджет не утверждён, monthly_limit=null означает BLOCKED, а не «безлимит». Одного ATHENA_PAID_TTS_ENABLED=true недостаточно для утверждения месячного бюджета. Автопокупка или upgrade подписки запрещены без решения владельца.

Учитываются previews, повторные вызовы, style tags, вспомогательная LLM-нормализация и собственные вычисления. Таймаут может оставить стоимость UNKNOWN. Резерв не освобождается как «не потраченный» без сверки. На OpenRouter сохраняется X-Generation-Id, если получен; окончательная стоимость сверяется доступным provider usage/billing механизмом, а не выдумывается по MP3.

Расчётный тариф фиксируется до платного dispatch. Если нельзя установить одобренную RateCardRevision и верхнюю оценку, новый paid вызов BLOCKED. UNKNOWN после вызова означает неизвестную фактическую стоимость, а не отсутствие выбранного расчётного тарифа. SpeechUsage сохраняет эту pinned rate revision; последующая сверка добавляет actual usage/adjustment с provenance, не подменяет старую запись. No-charge engine не требует фиктивного paid account/reservation/usage.

16. Подписки на уведомления

NotificationSubscription определяет principal, scope, типы событий, источник/board/task filters, канал, проверенного получателя, режим озвучивания, правило выбора профиля, quiet hours, cadence и статус. Это не коммерческая подписка.

По умолчанию каждое техническое событие не озвучивается. Пользователь явно включает нужные категории: задача завершена, требуется ответ, критический сбой. Получатель назначается доверенной стороной; его нельзя подменить полем карточки.

Дедупликация использует event revision, recipient, channel и revision подписки. Частые технические обновления можно агрегировать. Точные расписания и quiet hours согласуются отдельно.

Kaiten event → проверка/REST reread → разрешённая проекция события → сообщение Hermes → optional TTS. Событие обработки памяти Honcho само по себе не создаёт уведомление. Смена профиля или ошибка TTS не запускает рекурсивную цепочку голосовых оповещений.

17. Проекция текста для речи и приватность

Canonical MessageRevision — неизменяемый текст ответа или утверждённого уведомления. SpeechProjection хранит произносимый текст, версию преобразования, ссылки на источники и hash. Видимый текст не перезаписывается скрытым TTS preprocessing.

Данные Honcho и Kaiten проходят read ACL, минимизацию и формирование ответа до TTS. Право прочитать рабочую карточку не означает право передать её внешнему голосовому провайдеру. Для каждого облачного маршрута проверяются допустимые классы данных и условия поставщика. Edge тоже является внешней обработкой.

Режимы: off, mirror_text, concise_summary. Краткая озвучка — отдельная проекция с обозначенными ограничениями, не тихое обрезание текста. Нормализация чисел, валют, дат, отрицаний и идентификаторов не меняет смысл. Примеры «1С», «БИТ.Финанс», суммы и проценты входят в приёмку.

Недоверенный текст карточки может содержать markup, audio tags или инструкции. Они не становятся командами движку. Style instructions поступают только из разрешённого профиля. Внешнему TTS не отправляются полный prompt, memory store, credentials, внутренние логи или скрытая история.

18. Спецификация API синтеза речи

Ниже проектный API Афины, не native endpoints Hermes или Honcho. Он может быть реализован закрытым HTTP-сервисом, Unix-каналом или in-process фасадом. Новый публичный порт не требуется. У исходящего сообщения только один владелец автоозвучки: native handler либо контроллер, но не оба параллельно.

Общий интерфейс адаптера: synthesize(SynthesisRequest, scoped_dependencies) → SynthesisResult. Разрешённый запрос содержит message/projection/profile revisions и формат доставки. Provider URL, ключи, произвольный output path и shell template от клиента не принимаются.

|Method/path|Результат|Gate|

|---|---|---|

|GET /athena/v1/voice/profiles|Доступные профили и capabilities|ACL до metadata, без секретов|

|GET /athena/v1/voice/selection|Текущий разрешённый выбор|Scope check, без секретов|

|PUT /athena/v1/voice/selection|Новая selection revision|Trusted actor, expected_version, readiness|

|POST /athena/v1/tts/jobs|Durable job receipt|ACL, privacy, entitlement, budget, idempotency|

|GET /athena/v1/tts/jobs/{id}|Состояния, ошибки, usage, artifact refs|Owner/scope check|

|POST /athena/v1/tts/jobs/{id}/cancel|Cancel request|Expected version; no refund promise|

|GET /athena/v1/tts/jobs/{id}/audio|Проверенные аудиобайты|READY, live access/rights, retention|

|POST /athena/v1/voice/previews|Preview job|Разрешённый короткий текст и отдельный paid budget|

|POST /athena/v1/deliveries|Delivery receipt|Разрешённый target и существующий artifact|

|GET /athena/v1/deliveries/{id}|Delivery state/receipt|Scope check|

Внешний клиент передаёт message_revision_id, а не неограниченный сырой текст. Доверенный internal preview может содержать synthetic text после той же проверки. Схема OpenAPI поставляется как design contract; API-сервер этим документом не создан.

Контракт FINAL-D1: JobStatus возвращает version для CancelRequest.expected_version, profile_id и числовую profile_revision. Для READY обязательны audio_artifact_id и audio_metadata: sha256, codec, container, duration_seconds, sample_rate_hz, channels. Состояния delivery имеют собственный enum и не смешиваются с synthesis. Delivery Receipt требует id/status/version/audio_artifact_id. Все 4xx/5xx имеют SafeError; 404 не раскрывает существование чужого объекта. Preview доступен только trusted preview actor: сервер внутри idempotent acceptance создаёт scoped synthetic MessageRevision и SpeechProjection. Это synthetic, не второй conversation turn и не ingest Honcho. Повтор preview использует те же refs. API остаётся проектным; сервер не создан.

19. Примеры API и идемпотентность

```http
POST /athena/v1/tts/jobs
Authorization: Bearer <internal-scoped-token>
Idempotency-Key: <unique-operation-key>
Content-Type: application/json
```

```json
{"message_revision_id":"msg-042-r1","profile_id":"athena_natural","delivery_format":"telegram_voice"}
```

Profile ID — разрешённый выбор, не обход selection policy. Principal/scope берутся из проверенной identity. Сервер фиксирует разрешённую projection и profile revision. Hash исполнения включает engine/model/voice/format/policy, но повтор того же клиентского ключа сначала находит прежнее разрешение, не пересчитывает его по новому default voice.

Одинаковые key+actor+request возвращают прежний receipt. Иное тело с тем же key — 409. Истёкший кеш не даёт права автоматически повторно оплачивать прежнюю бизнес-операцию. Срок хранения idempotency records согласуется отдельно.

```json
{"job_id":"speech-042","status":"QUEUED","version":1,"profile_id":"athena_natural","profile_revision":1,"billing_status":"reserved","delivery_status":"not_requested"}
```

202 означает локально сохранённое принятие, не успешный синтез или доставку. GET при READY возвращает audio_artifact_id, sha256, codec/container, duration/sample_rate/channels и billing status. Сырые пути хоста, ключи и provider error bodies не возвращаются.

POST synth не отправляет голосовое автоматически. Delivery использует отдельный idempotency key и уже готовый artifact; сбой транспорта не повод снова вызвать платную модель.

Ключ повтора: verified actor + privacy scope + operation kind + Idempotency-Key. Уникальность и lookup/insert обеспечиваются атомарно. Digest строится по валидированному клиентскому телу, не по новым generated refs/defaults. Перед возвратом прежнего результата — live ACL. Delivery хранит свой key и digest, смена target требует новой операции/согласования. До утверждения retention idempotency records не очищаются автоматически. Утрата record не разрешает replay.

20. Контракты внешних TTS-адаптеров

|Backend|Запрос|Особенности|

|---|---|---|

|Edge|Штатный Hermes adapter/library|Онлайн Microsoft; стабильный публичный REST contract не выдумывается|

|OpenRouter|POST https://openrouter.ai/api/v1/audio/speech; Bearer; model/input/voice/response_format|Raw MP3/PCM, не JSON; X-Generation-Id при наличии|

|ElevenLabs direct|Поддерживаемый SDK или native Hermes provider|Отдельные model IDs, voice IDs, key и entitlement|

|Fish direct|POST https://api.fish.audio/v1/tts; Bearer; model header; text/reference_id/format|Неизвестный model header отклоняется локально до запроса|

|Own engine|Versioned private API/command/plugin|Явные codec/capabilities/rights/auth/resource limits|

Начальный OpenRouter-профиль запрашивает MP3 явно. Для PCM обязательны фактические sample rate, channels, sample format и endianness. Неверный rate меняет скорость и высоту воспроизведения. Не отправлять speed/instructions, если модель их не поддерживает.

Правила маршрутизации speech не считаются идентичными chat routing. Privacy requirements сверяются по capabilities реального endpoint. Ключи прямого провайдера и OpenRouter невзаимозаменяемы.

Reference upload — только с правами, scoped access и ограничением размера. Произвольные URL не скачиваются без anti-SSRF/allowlist. Модель/voice/rate card закреплены revision и проверяются при активации.

На выходе проверяются HTTP status, bounded bytes, MIME, декодирование и ffprobe. Extension не доказательство codec. Для Telegram source MP3 конвертируется в Opus/OGG; raw PCM нельзя переименовать в MP3.

21. Состояния заданий, чанки и доставка

Synthesis: CREATED → VALIDATING → QUEUED → DISPATCH_INTENT → SYNTHESIZING → AUDIO_VALIDATING → READY. Дополнительные состояния: FAILED, BLOCKED, PARTIAL, CANCEL_REQUESTED, CANCELLED, OUTCOME_UNKNOWN.

Billing: not_required/reserved/settled/unknown. Delivery: not_requested/queued/sending/delivered/failed/unknown. Эти оси независимы: звук может быть готов, но не доставлен; запрос мог быть оплачен без пригодного аудио.

План чанков неизменяем: порядок, text digests, profile snapshot. На чанк выделяется attempt и provider request reference. Параллельность ограничена. Уже готовые чанки не перегенерируются из-за сбоя доставки. Неполная запись отмечается как PARTIAL, полный текст остаётся доступным.

Отмена queued job не вызывает provider. Отмена running — best effort, не гарантирует отсутствие списания. Unknown billing не превращается в ноль и не освобождает резерв до сверки. Продолжение после ошибки не меняет voice revision незаметно.

При потере channel receipt возможна уже выполненная доставка. Используется доступная сверка, а не выдуманная exactly-once гарантия Telegram. Успешная BusinessTask не становится FAILED только из-за синтеза или отправки голоса.

Переходы и инварианты заданы в Contracts/State_Transitions.csv. Любой изменяющий переход требует current version/CAS и live authority. Чанк имеет стабильные job_id+chunk_index и immutable text_hash; попытка различается attempt_no. Новый attempt допустим только после безопасного разрешения предыдущего UNKNOWN. CANCEL_REQUESTED не обещает возврат средств. READY не отменяет unknown billing; новая доставка не означает новый синтез.

22. Хранение конфигов, голосовых материалов и кеша

```text
/srv/athena/deployment/core/voice/ # managed code, schemas, templates
/srv/athena/state/hermes/<profile>/
config.yaml # native provider binding
.env # runtime secrets, 0600
honcho.json # отдельное подключение памяти
/srv/athena/state/voice/ # selections, jobs, receipts, budget refs
/srv/athena/model-assets/voice/<identity>/<revision>/
reference.* / transcript.txt / rights.json / manifest.json
/srv/athena/work/tts/<job>/<chunk>/ # временные ограниченные файлы
/srv/athena/warehouse/media/generated/tts/ # retained audio при необходимости
/etc/athena/secrets/ # provider credentials
```

Code/templates read-only, mutable state имеет одного владельца. Registry версионируется; выбор меняется через CAS. Секреты не находятся в профилях Git, карточках или памяти. env_passthrough — явное разрешение переменных, не полная ОС-изоляция процесса.

Cache key включает principal/environment/domain, разрешённую projection, engine/model/voice/profile versions, style, normalizer, codec и policy/rights revision. Нельзя переиспользовать аудио между scopes только из-за одинакового текста. Для короткого чувствительного текста обычный hash не анонимизация; использовать scoped HMAC и защищённые metadata.

Перед playback повторно проверяются доступ и отзыв прав. Numeric TTL и retention для voice assets, job receipts, audio и usage согласуются отдельно. Temporary cleanup не удаляет активные чанки и единственный экземпляр референса. Regeneration кеша может стоить денег.

Backup включает профили, выбор, права, manifests, нужный job state и защищённые secrets. Ключ восстановления хранится вне VPS. Акустические референсы не смешиваются с API credentials.

Числовые retention/TTL остаются решением владельца. До утверждения отсутствует автоматическое удаление retained originals/rights/receipts; scratch очищается только при terminal, отсутствии hold/lease/refs и подтверждённой публикации. Полный backup coverage: Contracts/Backup_Coverage.csv; секреты только в защищённой копии с внешним recovery key.

23. Реестр профилей: наш контракт, не native Hermes

```yaml
schema_version: '3.3'
selection:
scope: hermes_profile
active_profile: svetlana
version: 1
switch_policy: next_reply
fallback_policy: text_only
profiles:
svetlana:
  revision: 1
  enabled: true
  hermes_provider: edge
  engine: edge_online
  voice: ru-RU-SvetlanaNeural
  external_processing: true
  billing_route: no_api_charge
athena_natural:
  revision: 1
  enabled: false
  hermes_provider: athena_elevenlabs
  engine: elevenlabs_via_openrouter
  model: elevenlabs/eleven-v4-turbo
  voice: null
  credential_ref: openrouter_tts
  billing_account_ref: openrouter_main
  external_processing: true
  activation_requires:
  - chosen_voice
  - paid_budget
  - account_access
  - synthesis_delivery_test
athena_fish:
  revision: 1
  enabled: false
  engine: fish_direct
  model: null
  voice: null
  activation_requires:
  - model_selection
  - chosen_voice
  - paid_budget
  - synthesis_delivery_test
athena_own:
  revision: 1
  enabled: false
```

```
    engine: null
    voice_identity_revision: null
    locality: undecided
    activation_requires:
    - engine_selection
    - resources
    - rights_check
    - synthesis_delivery_test
athena_elevenlabs_direct:
    revision: 1
    enabled: false
    engine: elevenlabs_direct
    model: null
    voice: null
    credential_ref: elevenlabs_direct
    external_processing: true
    activation_requires:
    - account_plan_selection
    - chosen_voice
    - paid_budget
    - synthesis_delivery_test
```

Это проектный реестр3.3. Он не изменяет Hermes без controller/selector. Миграция registry сохраняет действующие профили и не включает записи с enabled=false. Источник фактического native выбора — effective config. Несовпадение registry и readback создаёт drift alert. Все paid-профили остаются заблокированными до voice/key/budget и приёмочного теста.

24. Native Hermes config и секреты

```yaml

## # Фрагмент, слить в существующий config.yaml, не два tts ключа.

tts:
provider: edge
speed: 1.0
edge:
    voice: ru-RU-SvetlanaNeural
    speed: 1.0
    max_text_length: 4000
providers:
    athena_elevenlabs:
      type: command
      command: >-
        python3 /opt/athena/voice/tts_adapter.py
        --backend openrouter --input {input_path} --output {output_path}
        --model {model} --voice {voice}
      model: elevenlabs/eleven-v4-turbo
      voice: REPLACE_WITH_CHOSEN_ELEVENLABS_VOICE_ID
      output_format: mp3
      voice_compatible: true
      timeout: 90
      max_text_length: 4000
      env_passthrough:
        - OPENROUTER_TTS_API_KEY
        - ATHENA_PAID_TTS_ENABLED
```

- ATHENA_TTS_MAX_INPUT_CHARS

```

```dotenv
OPENROUTER_TTS_API_KEY=
FISH_TTS_API_KEY=
ELEVENLABS_API_KEY=
ATHENA_PAID_TTS_ENABLED=false
ATHENA_TTS_MAX_INPUT_CHARS=4000
```

4000 символов и90 секунд — исходные проектные параметры, не месячный финансовый лимит. Native command timeout относится к отсутствию вывода; HTTP socket timeout60s в образце не является строгим общим deadline. Общий deadline и quota controller должны быть реализованы отдельно.

Command stdout/stderr может возвращаться модели, поэтому в нём запрещены секреты, полный текст и raw provider error bodies. Требования к будущему adapter: key/model/voice, bounded bytes/MIME, запрет redirects, atomic output, no auto-retry. В этом комплекте исполняемый tts_adapter.py отсутствует; никакое свойство его реализации не подтверждено. Он не реализует selector, monthly reservations, decode validation, cache, delivery ledger и streaming. Для plugin streaming отдельно проверяется потокобезопасность. Custom providers не должны подменять встроенные имена.

В комплекте native-фрагмент показывает Edge и ElevenLabs/OpenRouter. Fish/direct ElevenLabs/own engine пока зарезервированы в registry, не объявляются установленными provider bindings.

Шаблон native config — UNVERIFIED_TEMPLATE: ни один ключ не признан поддерживаемым без закреплённого runtime. /srv/athena/deployment/core/voice — host source; /opt/athena/voice — предполагаемый image destination; packaging ещё не реализован. До проверки adapter файл не переносится как готовая команда. Native-only Edge pilot и controlled TTS — разные режимы: CP-TTS/data scope и ручные synthetic tests обязательны, controller guarantees native-only режиму не приписывать.

25. Логическая модель данных 3.3

53 сущности 3.2 сохраняются по назначению: identity/scopes/projects; tasks/revisions/runs/stages/attempts/handoff/checks; artifacts/revisions/links/locations; governance/approval/roles/skills/model policy; inbox/outbox/audit/memory integration; budgets/usage/backup; десять сущностей Kaiten.

Добавляются 16 сущностей: VoiceEngineRevision, VoiceIdentityRevision, VoiceMaterial, VoiceProfileRevision, VoiceSelection, MessageRevision, SpeechProjection, SynthesisJob, SynthesisChunk, AudioArtifact, DeliveryAttempt, BillingAccount, EntitlementRevision, RateCardRevision, SpeechUsage и NotificationSubscription.

Engine хранит route/capabilities/version, identity — ссылки на разрешённые материалы, profile закрепляет их версии. Selection указывает конкретный profile revision. MessageRevision — canonical text и source refs; Projection — spoken text/transform/hash; Job — snapshot/idempotency/reservation; Chunk — порядок/attempt/provider receipt; AudioArtifact — verified ArtifactRevision+codec; DeliveryAttempt — exact target/channel receipt.

BudgetReservation расширяется: subject_kind/subject_ref поддерживают execution attempt либо synthesis job. Для голосового ответа не требуется создавать фиктивный BusinessTask или attempt. BillingAccount отражает путь оплаты, а не заменяет внутренний BudgetAccount. Provider balance cache имеет fetched_at и не выдаётся за банковский источник истины.

NotificationSubscription хранит scopes, события, получателя и selector. Все межхранилищные связи — logical references, не SQL foreign keys внутри Honcho/Kaiten. Новая DDL ещё не применяется. Озвучивание не меняет BusinessTask acceptance.

Нормативные логические constraints вынесены в Contracts/Logical_Constraints.csv; они дополняют ER/словарь, не являются vendor DDL. BudgetReservation: ровно один субъект; execution_attempt → attempt_id=subject_ref, synthesis_job → attempt_id NULL и subject_ref=job.id, job.reservation_id указывает обратно. Уникальность активного резерва по budget account + subject kind/ref; reserve+subject creation атомарны в owned store. Для cross-store intent требуется reconcile без видимого «принятого» orphan. Project содержит canonical scope_id; CONTEXT_SCOPE.project_id — optional обратная ссылка, выставляется после создания project. При наличии обратной ссылки она должна указывать на тот же project/scope; для остальных scopes project_id NULL.

26. Матрица ошибок и правила эскалации

Код	Действие	Повтор и эскалация
PROFILE_NOT_READY / VOICE_NOT_CONFIGURED	Не вызывать провайдера; сохранить текст	Настроить профиль, не подставлять голос по умолчанию
```

| SCOPE_DENIED / EXTERNAL_PROCESSING_DENIED | Отказать без выдачи аудио или чужого кеша | Не переключаться на другой облачный сервис |

| SUBSCRIPTION_INACTIVE / KEY_INVALID | Заблокировать выбранный маршрут | Администратор; без автоматической покупки |

| BUDGET_NOT_APPROVED / BUDGET_EXCEEDED | Не выполнять новый платный вызов | Решение владельца либо text-only |

| RATE_LIMITED | Ограниченное ожидание в рамках deadline | Retry-After и проверка receipt, без бесконечных повторов |

| PROVIDER_NETWORK_TIMEOUT | Исполнение и стоимость могут быть UNKNOWN | Reconcile до повторного платного запроса |

| MODEL_UNAVAILABLE / UNSUPPORTED_OPTION | Отклонить точный профиль или опцию | Не менять модель/голос молча |

| INVALID_AUDIO / EMPTY_AUDIO | Не отправлять повреждённый результат | Внешний запрос мог быть оплачен; отдельная сверка |

| CONVERSION_FAILED | Ограниченно сохранить валидный исходный звук | Повторить локальное преобразование, не синтез |

| DELIVERY_FAILED | Готовность аудио не сбрасывать | Повторить разрешённую доставку готового artifact |

| DELIVERY_OUTCOME_UNKNOWN | Не объявлять сообщение недоставленным | Сверка доступного канального receipt |

| PARTIAL_SYNTHESIS | Явно обозначить неполную озвучку; полный текст доступен | Продолжение по policy без смены голоса |

| STORAGE_FULL / MOUNT_MISSING | Остановить новые записи; mount guard | Оператор; не создавать пустую БД на rootfs |

| PROFILE_REVOKED / RIGHTS_REVOKED | Запретить новые jobs и выдачу кеша | Проверка прав и lifecycle |

| CANCELLED | Не возобновлять автоматически под другим профилем | Указать возможное списание |

| HONCHO_UNAVAILABLE / KAITEN_UNAVAILABLE | Обязательный источник — block; иначе явный degraded | Не ошибка TTS; не выдумывать контекст |

Ошибки возвращают безопасные code, job_id, correlation_id и retry classification, без ключей, полного текста и raw provider traceback. Успешная задача не становится FAILED из-за озвучки. Callback-исключение не отменяет внешние эффекты.

27. Безопасность и границы контекста

Авторизация выполняется до listing, preview и audio fetch. Знание UUID не является доступом. Кеш и голосовые материалы наследуют privacy domain и проверяют отзыв прав.

Read permission не равно external-processing permission. Нельзя передать запрещённые персональные/медицинские/платёжные данные в облако под видом «просто озвучить». Для local-only данных Edge также не подходит, поскольку является внешним сервисом.

Optional SDK input_filter/nesting не ограничивает shared dependencies, tools или server-side conversation history. Handoff минимален; tool broker применяет live grants. Secret canaries проверяются в model input, child env, logs и streams.

Служебные DB/cache/metrics не публикуются. Proxy один, private/loopback endpoints, IPv4/IPv6 проверяются отдельно. Docker firewall backend определяется фактически; UFW не считается единственной защитой опубликованных портов. Никакого docker.sock агентам.

Endpoint и shell template — trusted config. Redirect/reference fetch ограничены anti-SSRF. Права на голос и допустимость клонирования проверяются до обработки, а не после создания модели. Удаление/отзыв прав и backup retention — отдельные согласованные процедуры.

Приоритет ACP r2: Yellow в standing approved profile не требует approval каждого сообщения/обезличивания всех имён; новое назначение/scope/gated action требует отдельного допуска. Black — no AI content даже local; Red — без approved isolated backend affected operation BLOCKED. Минимальные checks реально включённых путей обязательны; отдельный PDP/broker, total DLP и полный anti-bypass gateway не prerequisite Core. Матрица enforcement и coverage: Contracts/Boundary_Matrix.csv, статус DESIGN / NOT_VERIFIED. До функциональной проверки synthetic-only pilot, без медицинских/банковских/клиентских материалов.

28. Логи, backup и восстановление

Один primary на каждый класс данных. Honcho использует dedicated filesystem/UUID, mount доступен до auto-restart контейнеров. External named volume сам по себе не доказывает отдельный диск. Образы и Docker logs могут находиться вне этого тома.

Проектная ротация: local driver 10m × 5 с compression; это size retention, не гарантированные дни хранения. PostgreSQL stderr без дублирующего collector. Proxy/journal/file logs ограничиваются отдельно. Raw SQL, spoken text, audio base64, Authorization и ключи не попадают в обычный журнал ошибок.

Согласованный full image — ежедневно в 00:00 Europe/Moscow, все требуемые диски; затем Windows → Kingston и isolated restore. Preupgrade pg_dump дополняется roles/extensions/config/secrets. Hash или archive list не заменяет restore test. Hosted Kaiten и provider Voice Library не входят в VPS image: экспорт и права отдельно.

После восстановления интеграции сначала сверяют current remote state и pending intents в read-only режиме. Нельзя автоматически повторить озвучку или публикацию из старого outbox без проверки receipts. Voice assets/rights — обязательная часть защиты; cache regeneration допускается только с учётом цены. RPO/RTO и retention остаются открытыми.

Запись backup evidence отдельно перечисляет native home, Honcho PG/Redis, Project DB, Catalog/warehouse, governance, voice state/assets/rights, deployment metadata и encrypted secrets; временные файлы только по retention policy. Стрелка на схеме не доказательство coverage. RPO/RTO открыты.

29. Deployment: новая установка и условный импорт старых данных

Новая Афина ещё не развёрнута. Основной путь — fresh install; наличие прежней 3.2 не предполагается. Действующий порядок подготовки — HANDOFF-DEPLOY-001 r1 из коммита 504c0520f5f53a6bc1faa18cef5e03704909c245. Его исходный текст доступен по закреплённой ссылке в Deploy/README_DEPLOY_RU.md; этот выпуск не выдаёт пересказ за исходник.

Порядок: baseline/recovery и новый read-only inventory → согласованные ресурсы/storage/UUID → pin/compatibility/settings → ограниченный executor/Core → checkpoint → Honcho → checkpoint → optional voice → последующие Catalog/Team/Kaiten. Health & Fitness, дополнительный model gateway, Little LLM, draft и сложный Admin Approval plane не блокируют первый ограниченный запуск; агенту host/Docker/security/destructive management не выдаются.

Никакого docker compose up до recovery и проверки применимости. Не складывать независимые Compose-проекты через -f; dashboard overlay проверяется отдельно в итоговом merged config. Полный prepare_storage не core-only bootstrap. Не создавать fake gates/images, не подставлять UUID root ради PASS. Политика approval не даёт разрешения на серверные изменения.

Legacy import только если реально найден источник: сохранить отдельную копию config/assets/receipts; определить совместимость и provenance; предложить scoped import plan, проверить на копии и согласовать. Не выполнять миграцию фиктивного source state. Старые uploads/backups не удаляются.

CI/CD: reviewed code, no prod secrets в PR, build once/pinned digest, точное change approval, функциональные тесты и rollback. Image downgrade не отменяет DB migrations/charges/delivery; после restore read-first reconcile. Конкретный runtime release и команды выбираются отдельно; v0.23.0 не закрепляется этим выпуском.

30. Ресурсы и наблюдаемость

Исходный бюджет Honcho 4 vCPU / 8 GiB / 100 GiB данных сохраняется как проектный ориентир, не факт о VPS. Пример RAM: DB 3 GiB + API 1 + Deriver 1.5 + Redis 0.5 = 6 GiB контейнеров, ещё 2 GiB — резерв ОС. Core и workers требуют дополнительного бюджета. Один миллион vector(1536) — около 5.729 GiB чистых векторов, без индексов/текстов/WAL.

TTS контролирует очередь, profile/config revision и drift, availability, provider latency P50/P95, decode/conversion time, delivery receipts, unknown charges, reserved/settled usage, disk/bytes/deadline/concurrency. Полный spoken text не нужен для метрик.

Health/readiness не доказывают качество аудио. Проверяются ffmpeg/libopus, актуальный sample rate, допустимые пути, privacy и одна authority автоозвучки. Healthcheck не делает paid synthesis каждую минуту. Для полного падения VPS нужен внешний watchdog и фактически проверенная доставка alerts.

31. Матрица приёмки

Базовые gates: личные текст/голос/файлы до проверенного результата; auth/IPv4/IPv6; честная target-проверка Excel; memory new-session/recreate/correction; role handoff и независимый QA; snapshot-bound checks; acceptance отдельно от release; runtime grants; idempotency/unknown/restart; budgets; background work без ноутбука; persistent dependencies; full image/independent restore; requirement-to-evidence traceability; standalone без проекта/Team DB.

Kaiten gates K01–K09: scope denial; pagination; card links/snapshots; unknown write reconciliation; human edit conflict; Done не release; секреты/данные; post-restore reconcile; обычная работа при outage.

Voice gates:

|ID|Проверка|

|---|---|

|V01|Edge/Svetlana: текст → декодируемый звук → Telegram voice|

|V02|Платный профиль не вызывается без voice/key/budget|

|V03|Выбранные ElevenLabs route/model/voice доступны на аккаунте|

|V04|Смена только со следующего ответа, одинаковый snapshot всех чанков|

|V05|Неподдерживаемые style/speed не применяются молча|

|V06|Codec/container/rate проверены, нет PCM под видом MP3|

|V07|Ошибка TTS не уничтожает текст и успешную задачу|

|V08|Повтор доставки использует готовый artifact без нового синтеза|

|V09|Timeout/restart не даёт повторного неизвестного списания|

|V10|Нет scope leakage через cache/card/recall/output/logs|

|V11|Notification opt-in, quiet hours и dedup|

|V12|Нет повторной записи аудио/того же turn в Honcho|

|V13|Нет автоматической audio-публикации в Kaiten|

|V14|Voice rights, assets и restore проверены|

|V15|CAS selection и drift detection|

|V16|Overall deadline, disk/bytes и concurrency limits|

|V17|Command stdout/stderr не раскрывает private payload|

|V18|Один владелец автоозвучки, без двойного paid call|

Evidence: requirement → test → revisions → checks → decision. Неиспытанное помечается not_tested. Создание файла не подтверждает production readiness.

Применимость tests и expected results — Contracts/Acceptance_Tests.csv; policy gates SEC01–SEC16 трактуются по ACP r2, отложенные функции NOT_APPLICABLE_UNTIL_ENABLED, а не PASS. Статические проверки документов отделены от runtime NOT_RUN. Contracts/Traceability.csv связывает группы требований и замечания; не заявляет исчерпывающую историческую сверку всех ранних источников.

32. Последовательности голоса и уведомлений

```mermaid
sequenceDiagram
participant U as Андрей
participant H as Hermes
participant M as Scoped Honcho recall
participant K as Kaiten adapter
participant P as Speech projector/controller
participant B as Budget/entitlement
participant T as Selected TTS adapter
participant D as Delivery
U->>H: Поручение
H->>M: Только разрешённый recall
M-->>H: Контекст + источники/freshness
opt Нужны данные задачи
H->>K: Проверенный scope/read
K-->>H: Allowed card snapshot
end
H->>H: Выполнение + canonical message revision
H-->>U: Text output по policy
H->>P: Message revision + selected profile
P->>P: Privacy check + immutable projection/profile snapshot
P->>B: Reserve allowed cost / entitlement
alt Разрешено
B-->>P: Reservation
P->>T: Durable job/chunk identity + minimal speech text
T-->>P: Audio or typed error + provider request ID
P->>P: Decode/normalise/publish audio artifact
P->>D: Artifact + authorised recipient
D-->>U: Voice/audio
D-->>P: Receipt or delivery UNKNOWN
else Нет допуска / synth failed
```

P-->>H: Text-only, sanitized error, billing state
end
Note over M,K: Нет прямого потока всей памяти/карточек в TTS
```
```mermaid
sequenceDiagram
participant K as Kaiten
participant A as Integration adapter
participant N as Notification policy
participant H as Hermes message author
participant V as Voice controller
K-->>A: Poll result / verified optional event
A->>K: Authenticated reread if required
A->>N: Scoped event + CardTaskLink
N->>N: Opt-in/filter/quiet time/dedup
alt Уведомление разрешено
N->>H: Minimal event projection
H->>H: Canonical notification message
H->>V: Optional speech per subscription
else Не разрешено
N->>N: No notification/no paid TTS
end
```

33. Этапы и открытые решения

Этапы: уточнение оставшихся требований и моделей; inventory/independent copy; pinned compatibility; личная Афина; Honcho short synthetic smoke; командные контракты; параллельность/restart/cost; full backup/restore; Kaiten read/write gates; TTS profiles/paid preview/delivery policy.

TTS не задерживает установку основного текстового контура. Первый голос может оставаться Edge до готовности выбранного платного профиля.

Открыты: основная LLM Hermes; Honcho text IDs; ElevenLabs voice и account access; точный TTS budget/тариф; retention; события/quiet hours подписок; own engine/resources; реализация selector/hot reload/per-chat scope; endpoint/codec capabilities и deployment paths.

Выбранный embedding не открывается заново. Нельзя путать Honcho accepted с recall-ready, API key с per-user RBAC, Done с release approval или HTTP200 с delivered.

Открытые решения перечислены в Reports/Open_Decisions.csv: точные модели/digests/account routes/resources/retention/framework/local isolation не выдумываются. Принятие FINAL документов не выдаёт runtime grants и не утверждает произвольный provider.

34. Происхождение и изменения документального выпуска

Исходная v3.3 сохранена побайтово в historical/source_v3_3. Архив содержит её прежние manifest/validation только как историю. FINAL-D1 исправляет известные ошибки примеров, дополняет API/constraints/boundaries/test contracts и уточняет состав 8/9 и fresh install. Никакая исходная версия не перезаписывается задним числом.

Зафиксированный внешний контекст: ACP r2, HANDOFF и deployment-кандидат на коммите 504c0520f5f53a6bc1faa18cef5e03704909c245. Сам deployment tree в этот выпуск не скопирован и не исправлен. Известные замечания к нему — Deploy/Deployment_Errata.md. Historical r1/SYS/briefings/HTML/PNG не нормативные copies FINAL.

Проверки FINAL описаны в Validation_Report.json. Результаты прежних запусков не переносятся. Не заявлены полное покрытие всех исторических требований, runtime compatibility, Mermaid CLI rendering, server/SDK/provider/security tests. Выпуск завершён по текущему объёму инспекции решением владельца.

35. Источники и статус проверки

S1. GitHub: Colibri1985/manus-west-consulting-research, commit a6b081eaefc710e3fa8d7170876aea2bf57a74a9, каталог Athena_v3.2.&TTS. Canonical paths, Git blob SHA и размеры — в Source_Manifest.json.

S2. Hermes Voice & TTS: https://hermes-agent.nousresearch.com/docs/user-guide/features/tts
```

S3. OpenRouter TTS: https://openrouter.ai/docs/guides/overview/multimodal/tts

S4. Fish Audio: https://docs.fish.audio/api-reference/endpoint/openapi-v1/text-to-speech

S5. ElevenLabs billing: https://elevenlabs.io/pricing/api

S6. ElevenLabs use policy: https://elevenlabs.io/use-policy

Источники проверены 04.11.2026. Тарифы, модели и API capabilities повторно проверяются на выбранном release/account. /athena/v1, registry schema и новые сущности — проектные контракты, не уже работающие endpoints. Платная генерация, установленный Hermes, VPS и Mermaid renderer в рамках этого выпуска не запускались.

Текущие факты о provider API/models/prices здесь не перепроверены. Ссылки и историческая дата их проверки — provenance, не свежая сертификация. External ACP r2 — policy, приложенные PDF/MD сохранены без правок; исходные именованные документы не становятся отчётом наших runtime tests.

36. Комплект поставки FINAL-D1

Нормативный основной текст — этот Markdown, разделы 1–36. DOCX, PDF и RTF сформированы заново из его полного текста; формат .doc — RTF, не Word97. Форматирование упрощено: Mermaid и таблицы представлены текстом, без обещания WYSIWYG-эквивалентности. Нормативные машинные контракты — OpenAPI, ER, Entity Dictionary, Contracts/*.csv и voice design files в указанных областях. При реальном конфликте конкретный шаг останавливается до явного решения; priority disclaimer не заменяет исправление.

Mermaid: versioned overview и 01 — одинаковые aliases, 02 physical, 03 data, 04 ER, 05 workflow. ER содержит 69 логических сущностей; фактическое число связей пересчитано в текущем validation. Новые CSV constraints — логическая детализация, не физические таблицы Hermes/Honcho/Kaiten.

Старые PNG и визуальные исторические материалы помещены только в historical. В FINAL не выдаются за актуально отрендеренные .mmd. Новые нормативные схемы — текстовые Mermaid; renderer не запускался. Путь reader PDF не заменяет полную схему.

Source_Manifest.json описывает происхождение; Release_Manifest.json — текущие пути, размеры, SHA-256 и статус. SHA256SUMS.txt проверяет все текущие файлы кроме самого себя; это не цифровая подпись. Reports содержит dispositions всех известных замечаний: fixed_documentation / clarified / deferred_to_feature / open_verification. FINAL не означает все замечания runtime устранены.

Архив пригоден для хранения как документальная база v3.3 FINAL-D1. Deploy — только через отдельные stage gates; для Hermes v0.23.0 требуется отдельная v3.3.1.