Афина 2.0: уточнённые классы и ближайшая модель работы

Дата: 05.11.2026. Основа: принятый владельцем принцип управляемой автономности из сообщений 12:29 и 12:37; уточнённая модель цветов и этапов представлена сейчас для утверждения.

Афина использует заранее одобренные сервисы для разрешённого scope без подтверждения каждого запроса. Секреты исключены из AI-контекста; local-only и запрет памяти соблюдаются. Новые назначения и gated actions согласуются отдельно. Honcho работает штатно; скрытые альтернативные stores запрещены.

Точное разделение текущего плана

Механизм	Ближайший этап	Фактическая реализация
Правила классов + grants/profiles	Применимые обязательства, минимальная поддерживаемая интеграция и проверки	Согласование policy не равно работающему PEP/DLP; покрытие проверяется.
Fixed models per function	Основной диалог, Honcho text/embedding, STT/TTS — заранее выбранные назначения	Модели/route каждого профиля фиксируются отдельно, не одна модель для всей системы.
Little LLM Gate	НЕ используем; можно внедрить позже	Не установлен/не подтверждён как рабочий механизм.
LLM Gateway / LiteLLM	Отдельный следующий этап при полезности; static routes без autoswitch	Наличие документа не доказывает deployed gateway; version/auth compatibility отдельно.
Dynamic local/cloud model routing	НЕ используем на ближайшем этапе	Отсутствие local backend не оправдывает Red→cloud.
Draft/speculative decoding	НЕ используем; отдельный поздний inference benchmark	Не часть Black/Red/Yellow/Green и не security gate.

Граница утверждения

Этот review-пакет не изменяет ACP-SEC-001 r1, спецификации, GitHub или сервер. После явного подтверждения готовится следующая согласованная редакция ACP. В данном документе нет credentials, новых model IDs, numerical budgets или deployment commands.

Black и Red: узкие жёсткие границы

Black · Секреты не становятся AI-контекстом

Критерий	Предлагаемое правило
Что относится	Значения секретов: пароли, токены, приватные ключи, session cookies и другие credentials. Не вся техническая информация автоматически Black.
Примеры	API key, PEM private key, пароль БД, raw .env с секретами.
Допустимая обработка	Никакой LLM, включая local Little LLM; исходный AI/content packet блокируется. Trusted deterministic scanner может читать ограниченные bytes по policy.
Внешняя передача	AI/content передача запрещена; обычное approval не снимает запрет. Credential-use у коннектора — отдельный scoped auth-путь.
Память / хранение	Не Honcho, не MEMORY.md/skills/заметки/RAG/ordinary logs. Incident metadata без значений; secret store — отдельный класс назначения.
Поведение и согласование	Остановить затронутую операцию, безопасно сообщить владельцу. Не останавливать все несвязанные безопасные задачи.
Изменение допуска	Для дальнейшего разбора/нового безопасного пакета — отдельное действие. Не маскировать повтор того же заблокированного пакета.

Red · Только явно утверждённый изолированный контур

Критерий	Предлагаемое правило
Что относится	Материалы с явным local-only обязательством, договорным/правовым запретом передачи или иным отсутствием права на cloud processing.
Примеры	Документ «только локально», запрещённые к внешней обработке клиентские данные. Не все рабочие документы Red.
Допустимая обработка	Только approved isolated trust zone и допустимые локальные инструменты/модели. Если такого backend нет, соответствующая работа BLOCKED/deferred.
Внешняя передача	Запрещено: OpenRouter, cloud LLM, embedding, STT/TTS и другие внешние processing routes. Свой VPS не автоматически утверждённый local boundary.
Память / хранение	Не в текущий cloud-assisted Honcho pipeline. Отдельный разрешённый local store — только если он явно предусмотрен, не скрытая замена памяти.
Поведение и согласование	Разрешённая локальная работа без лишних вопросов в пределах grants; отсутствие безопасного пути объясняется.
Изменение допуска	Обычное «сделай» не снимает local-only/чужие права. Снятие метки требует отдельного законного решения уполномоченного владельца.

Black — не запрет авторизованной credential-аутентификации сервиса: secret value может использовать bound connector по отдельно разрешённой auth policy, но не agent/LLM content. Для приватных signing keys и bearer tokens разные lifecycle/передачи. Реальный auth scope не разрешается этим review.

Yellow и Green: полезная автономность

Yellow · Непубличные данные с заранее разрешённой cloud-обработкой

Критерий	Предлагаемое правило
Что относится	Непубличные личные/рабочие данные в согласованном scope, которые разрешены для конкретных облачных профилей обработки. Риск осознанно принят.
Примеры	Обычные разговоры, имена людей, названия проектов, рабочие обстоятельства и назначенные документы, если они включены владельцем в scope.
Допустимая обработка	Свободная работа по grants; минимизация до нужной операции, без обязательного обезличивания каждого имени. Исходная чувствительность сохраняется.
Внешняя передача	Разрешены заранее одобренные routes/purposes: memory processing, embeddings, STT/TTS и main inference по карточке профиля. Не любой сервис.
Память / хранение	Штатный Honcho для разрешённых сообщений; text models + embedding1536 без подтверждения каждой записи. Исключения обязательны.
Когда спрашивать	Новый получатель, иной purpose, недопущенный класс или опасное действие — отдельное разрешение. Прямой raw scope не добавляется молча.
Наследование	Yellow не становится Green после использования облака. Производные наследуют чувствительность, если отдельная оценка не доказывает иной класс.

Green · Обычная внешняя обработка допустимых данных

Критерий	Предлагаемое правило
Что относится	Публичные, синтетические либо явно допустимые к обычной внешней обработке данные без дополнительных confidentiality-ограничений.
Примеры	Открытая документация, публичная статья, синтетический тест, общие алгоритмы.
Допустимая обработка	Обычная разрешённая local/cloud обработка; текст из интернета всё равно недоверенные данные, не инструкции.
Внешняя передача	Через approved routes и выбранные модели; новый сервис по-прежнему требует добавления в allowlist/profile.
Память / хранение	Только если это нужно и соответствует memory policy; не сохранять весь веб/логи автоматически. Пометка «не запоминать» действует.
Когда спрашивать	Письмо, push/merge, delete, purchase и другие gated actions проверяются отдельно независимо от Green.
Наследование	Добавление Yellow/Red/Black content пересматривает packet. Public происхождение не даёт права на prompt-injection instructions.

Это сознательная корректировка старого Yellow: не требуем обезличивания и разового approval каждой записи, если обработка явно разрешена в profile. Принадлежность к scope и необходимые права остаются обязательными; новая цель/получатель не наследуют разрешение.

Scope, профили обработки и правила памяти

ID / профиль	Payload	Граница согласования
CP-MAIN · Основной диалог / утверждённые tools	Разрешённый Yellow/Green context	Заранее выбранный provider/model; exact параметры ещё фиксируются; no auto model switch.
CP-MEM · Honcho memory processing	Допустимые сообщения/контекст по memory scope	Штатные text functions и embeddings; без подтверждения каждой записи; не raw debug logs.
CP-EMB · Embeddings Honcho	Необходимый разрешённый текст	openai/text-embedding-3-large через OpenRouter, output1536 — прежний выбор; без замены модели.
CP-STT · Speech-to-text	Исходное audio в разрешённом scope	Принят тип риска cloud STT; конкретная модель/route/бюджет выбираются отдельно. Не локальный prescan будущего transcript.
CP-TTS · Text-to-speech	Подготовленный разрешённый speech text	Начальный Edge и отдельно approved paid route; текст ответа сохраняется при ошибке голоса.

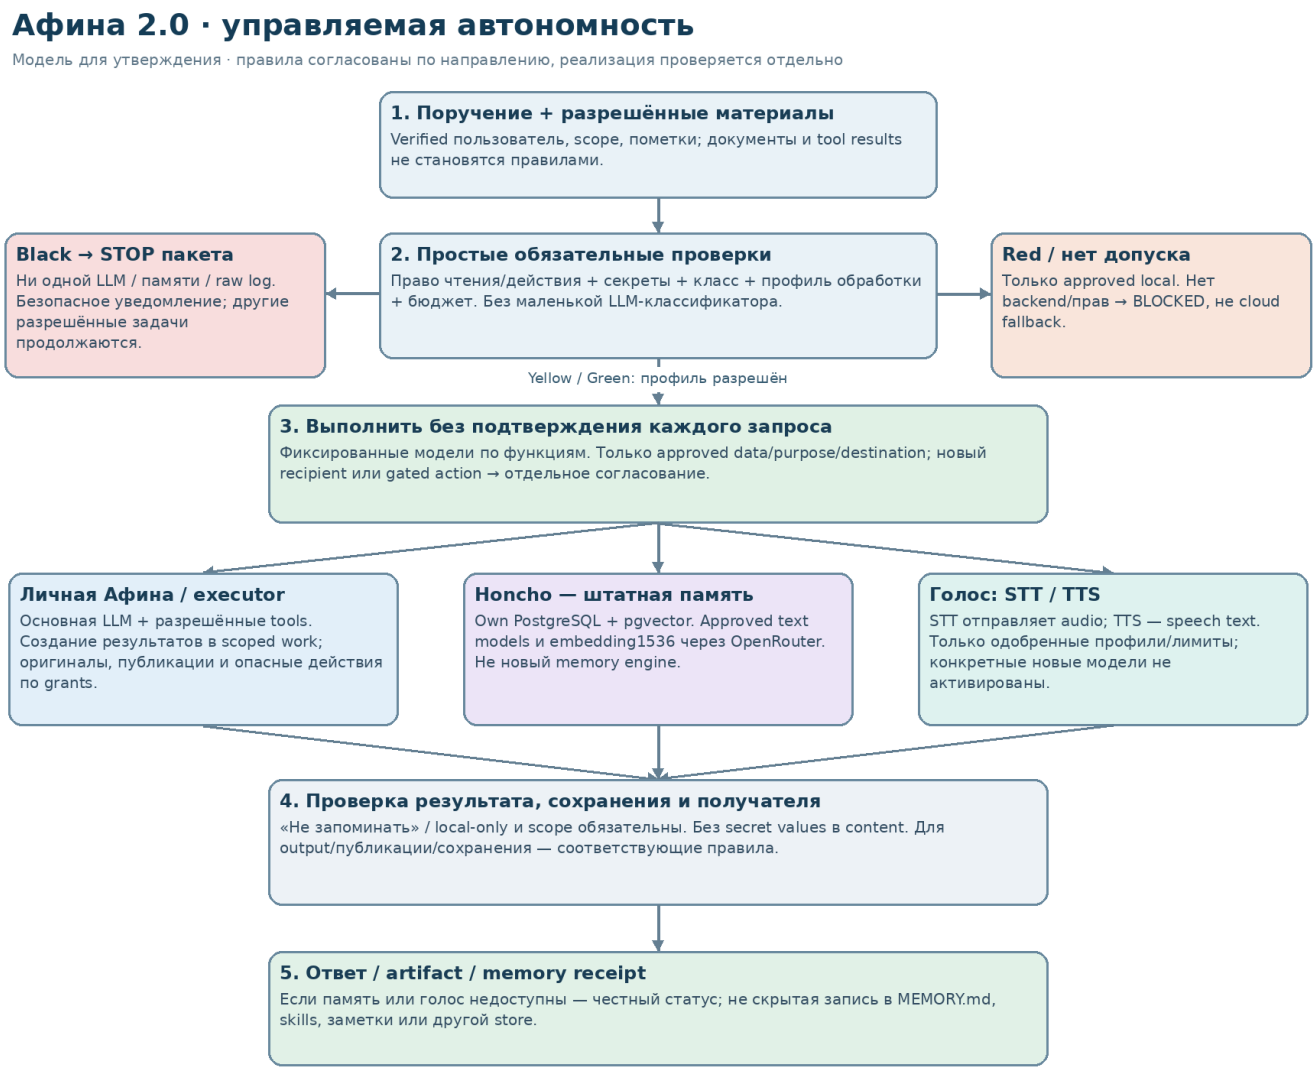
Независимые пометки — не дополнительные цвета

Пометка	Что означает
Не запоминать	Не отправлять в долгосрочную память Honcho; не создавать скрытую замену в MEMORY.md/skills/notes. Временная обработка возможна только по разрешённому profile.
Не сохранять содержимое вообще	Более строгое требование к history/cache/attachments/logs и provider retention. Пока это не поддержано и не проверено, система не обещает total absence копий.
Только локально	Ограничение всех внешних processing routes независимо от того, как пользователь назвал цвет.
Нет права передачи	Нельзя включить в permitted cloud scope одним удобством; решение уполномоченного владельца/правовое основание отдельно.
Unknown / mixed	Не авто-Green. Source labels и весь накопленный context важнее цвета последнего сообщения. Нужна проверка/уточнение допустимого режима.

Автоматически не собираем: секреты; «не запоминать»; local-only; данные без права передачи; полные служебные dumps/logs/process environment «на всякий случай». Обычные имена/проекты/связи разрешённого профиля не вырезаем. Derived content наследует ограничения, пока отдельная assessment не доказывает иной допуск.

STT передаёт исходное audio до получения transcript: нельзя обещать secret-screen будущего текста без local transcription. Cloud-risk принят по типу обработки; exact models, provider retention и paid caps отдельно. OpenRouter/provider и канал могут иметь собственные условия хранения; не обещаем абсолютный ZDR без проверки.

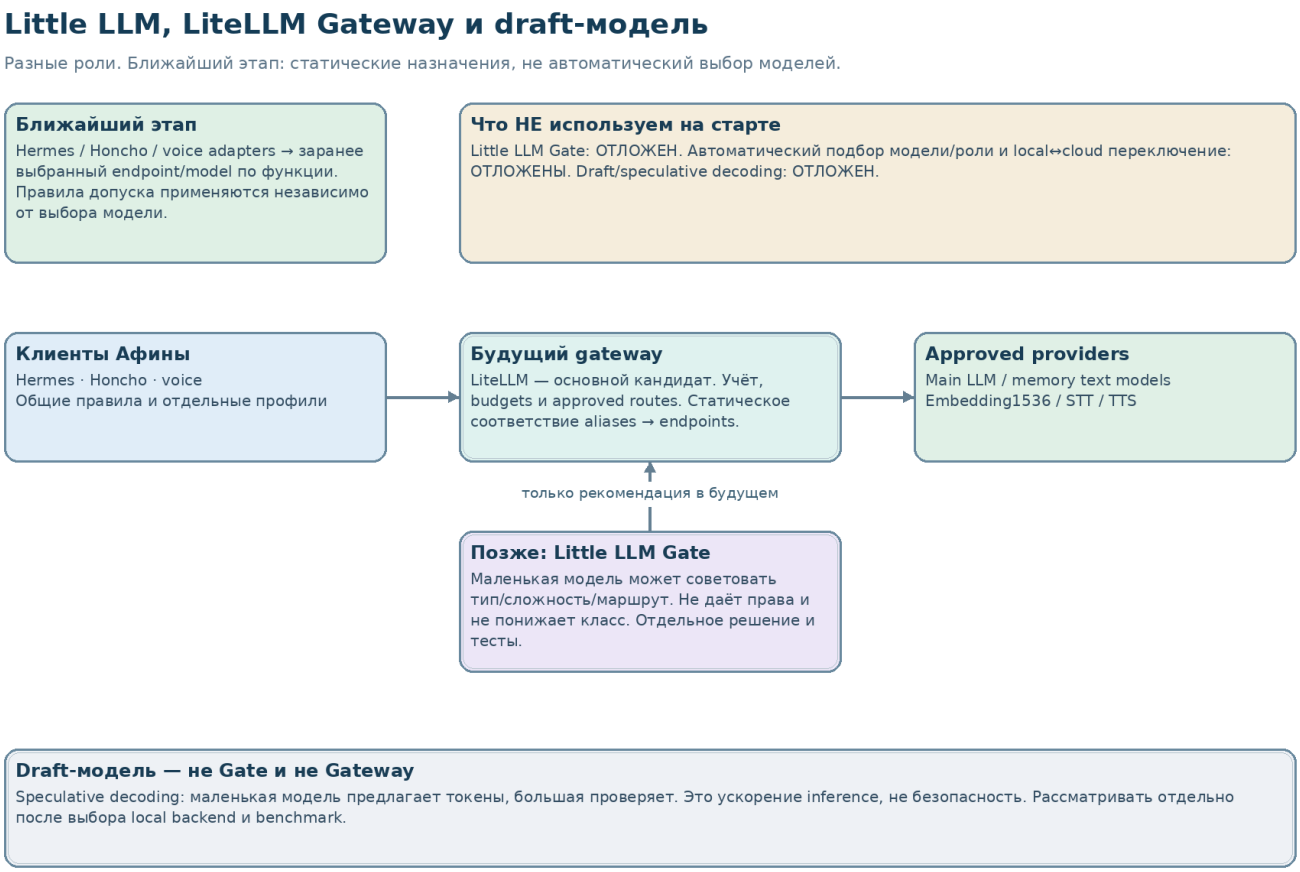
Схема 1. Рабочий поток Афины 2.0



Это схема целевого ближайшего поведения, не подтверждение внедрения. Ограничение затрагивает соответствующий packet/action, а не всю Афину. Продолжение безопасных задач допустимо. При сбое Honcho/voice — явный статус, не выдуманное сохранение или обходной store.

Согласованные правила не обещают perfect secret detection или zero bypass без интеграционных тестов. Минимальные поддерживаемые checks вводятся постепенно; новые автономные sensitive-data сценарии не считаются проверенными по одной схеме.

Схема 2. Gate, Gateway и draft: разные роли



Существование разных фиксированных моделей для разных функций ≠ динамическое переключение.

Термин	Простое объяснение	Решение для ближайшего этапа
Правила / Policy checks	Код и утверждённые настройки: кто/что/куда/зачем может передавать	Нужны сейчас как policy; реализация поэтапная.
Little LLM Gate	Маленькая модель советует о сложности/типе и позже маршруте; не выдаёт permit	Отложен. Система не ждёт его появления.
LLM Gateway / LiteLLM	Программный API-шлюз, не модель. Fixed endpoints/aliases, контроль и учёт при интеграции	Можно позже, статически. Не условие штатного старта Honcho.
Draft model	Предлагает токены основной модели для ускорения, не классификации/авторизации	Отложена. Только с подходящим backend/benchmark.

Факт «всё на VPS» не означает inference на CPU VPS: модель может быть cloud. Здесь отключаем динамический выбор между моделями, а не отрицаем разные выбранные модели у разных функций. Менять профиль вручную в будущем — отдельная операция, не скрытый fallback.

Что представлено для утверждения и как изменится ACP

Пункт	Предлагаемое решение	Влияние на ACP после одобрения
Модель цветов	Black/Red строго в своей узкой области; Yellow допускает standing approved cloud profiles; Green не отменяет grants	Уточнить D02 и CR02/CR10; убрать обязательное обезличивание каждого Yellow-запроса.
Honcho	Не менять memory engine/embedding выбор; штатный pipeline для permitted scope с точечными exclusions	Уточнить D06/CR08; no hidden alternate stores; нет новой local memory subsystem.
Model selection	Static model/provider per function; без автоматического complexity/role/local-cloud selection	Уточнить D04/CR05, совместимость проверять только при gateway pilot.
Gateway	Не утверждается как установленный. Реализация отдельным шагом, не обязательный prerequisite всех функций	Снять обязательную gateway migration как стартовый blocker; сохранить точки расширения.
Little LLM / draft	Оба отложены; Little LLM advisory only, draft — отдельная future optimization	D09/CR14 отложить; не добавлять draft в security scope.
Approval frequency	Постоянный допуск внутри profiles; новый recipient/purpose/опасная операция отдельно	Уточнить D01/D03/D10: автономность без per-request consent в approved area.
Проверки	Проверить exceptions/secret handling/receipt/status/no alternate stores; не обещать тотальный enterprise DLP	Упростить rollout/tests до реально принятого scope; остаётся NOT_TESTED до evidence.

Предлагаемая формулировка утверждения

«Утверждаю SEC-MODEL-REVIEW-001 r1: уточнённые Black/Red/Yellow/Green, профили облачной обработки и правила памяти. На ближайшем этапе — фиксированные модели по функциям; без автоматического routing, Little LLM Gate и draft-модели. Gateway внедряем позже отдельным этапом. Подготовь соответствующую редакцию ACP-SEC-001».

Approval этого review — архитектурная фиксация. Не deployment/network/token/billing approval. Точные data scopes, модели/credentials/budgets/retention конкретных processing profiles должны быть заполнены до реального подключения новых маршрутов.