ПОДПРОЕКТ · ЗАЩИТА КОНЦЕПЦИИ V1.0

Цифровой ML-инженер для локальной RAG-базы 1С:БИТ.Финанс

Детерминированный парсинг конфигурации и построение проверяемого knowledge layer

Внутреннее кодовое имя: **МИМИР**

Автор: Андрей Муллер

Для обсуждения с CEO / CIO / CTO / CDO

ВХОД

Конфигурация 1С
и разрешённые источники

ML ENGINEERING

Структура · метаданные
индексация · quality gates

РЕЗУЛЬТАТ

RAG и Evidence Pack
для цифрового аналитика

Конфигурацию 1С нельзя надёжно «загрузить в RAG как файл»

Цифровому аналитику нужен структурный и проверяемый слой знаний, чтобы сопоставлять требования, ТЗ подрядчика и фактическую реализацию.

01 / ИСХОДНИК

CF не является текстовой базой знаний

Метаданные, формы, модули, зависимости и правила поведения распределены по объектам и форматам.

02 / РИСК RAG

Чанки без структуры теряют смысл связей

Поиск может вернуть похожий текст, но не показать, какой объект, модуль или реквизит подтверждает вывод.

03 / КОНТРОЛЬ

Без quality gate нельзя доверять покрытию

Нужно измерить, что извлечено, что пропущено и можно ли воспроизвести тот же результат.

ВЫВОД **ML Engineering workstream** превращает конфигурацию в контролируемый knowledge layer — иначе Gap-анализ остаётся недоказуемой интерпретацией модели.

МИМИР — фундамент данных для доменных AI-агентов

Официальное название для руководства — «Цифровой ML-инженер». МИМИР — внутреннее кодовое имя разработки.

УРОВЕНЬ 1 · P0

FRIGGA ALL-MOTHER

Координатор портфеля, арбитр комплаенса, Inter-Project Protocol.

↓

УРОВЕНЬ 2 · P1–P2

Доменные эксперты

J.A.R.V.I.S. 2.0 — assurance и Evidence Chain.

Финансовый аналитик 1С — GAP, требования и ТЗ.

↓

УРОВЕНЬ 3 · ИНФРАСТРУКТУРА

Цифровой ML-инженер / МИМИР

Structural extraction, canonical graph, DLP, hybrid RAG, Evidence Pack.

Graph-first ядро

Объекты, связи, версии и исходные факты образуют структурный слой.

Производные слои

Hybrid RAG и LLM-Wiki добавляют retrieval и человекочитаемое представление — не заменяя источники.

Почему МИМИР — отдельный проект

Single Responsibility: извлечь факты отдельно, интерпретировать их отдельно.

Критерий	Цифровой ML-инженер / МИМИР	Цифровой аналитик 1С
ГЛАВНЫЙ ВОПРОС	Что технически существует в конфигурации?	Как это работает в бизнес-процессе?
ДОМЕН	Data Engineering, Static Analysis, RAG	BA, SA, 1С-экспертиза
КОМПЕТЕНЦИИ	AST, dependency graph, DLP, embeddings, retrieval	GAP-анализ, требования, ТЗ, трассировка
РЕЗУЛЬТАТ	Object Cards, canonical graph, evidence	GAP, OpenSpec, требования, бизнес-вывод
LIFECYCLE	Независимое развитие и масштабирование	Развивается независимо, использует факты МИМИРа

ПРИНЦИП **МИМИР отвечает за техническую истину конфигурации.** Аналитик отвечает за её бизнес-смысл.

Гибридный оркестрируемый pipeline

Локальное structural layer, DataOps, hybrid RAG и контролируемая периферия моделей.

Технологический стек

Вход	EDT / CF / XML / BSL
Парсинг	mdclasses · tree-sitter / BSL LS
Оркестрация	n8n · read-only jobs
Execution	OpenClaw / Hermes · Docker
Локальный контур	Ollama · Qdrant · audit trail
Интерфейс	AnythingLLM / controlled Gateway

Маршрутизация задач

Детерминированное ядро

Парсинг, AST, DLP, граф, чанкинг, embeddings и retrieval выполняются без внешнего LLM.

LLM-периферия

Описания, Wiki, GAP и reasoning — только по approved и обезличенному контексту.

Benchmark перед выбором

Кандидаты embeddings: BGE-M3 и multilingual-e5-large-instruct. Финальный выбор — по retrieval-тестам.

Экономика

Локальные операции — без стоимости внешнего inference; внешний контур — только для сложных разрешённых задач.

Parser-first: детерминированное ядро, LLM — только на периферии

Агент не является источником технической истины и не получает свободный доступ ко всему проекту.

n8n оркестрирует → OpenClaw / Hermes выполняет → ограниченные Skills формируют артефакты и отчёты

Без LLM	С LLM
`.mdo` · AST `.bsl` · DLP · граф · hash · retrieval	описания · Wiki · GAP · reasoning по approved facts

Зарегистрированные Skills	**bsl-static-parser** · **mdo-metadata-parser** · **dependency-graph-builder** · **dlp-sanitizer** · **object-aware-chunker** · **retrieval-evaluator** · **evidence-extractor** · **configuration-diff**
Ограничения	Docker-песочница · ограниченные контракты · read-only · approval для критичных действий · Production не изменяется

Локальный контур, DLP до AI-операций и явные границы MVP

Сначала доказывается воспроизводимость и безопасность pipeline на разрешённых данных.

GREEN

Публичные

Разрешённые источники и демо-материалы.

YELLOW

Внутренние

Только после проверки политики и scope.

RED

Конфигурация

CF/XML/BSL — локально, без внешнего egress по умолчанию.

BLACK

Секреты

Пароли, ключи, токены, ПДн — маскируются до любой AI-операции и никогда не передаются в LLM.

Контроль

Multi-layer DLP: regex, Gitleaks, TruffleHog. Source Register, audit trail, approval перед публикацией, rollback и read-only режим.

Граница MVP-A

Синтетическая EDT-выгрузка, Green-источники и synthetic Yellow-like context. Red-данные и Production-доступ — за пределами первого цикла.

HUMAN-IN-THE-LOOP · AI не назначает класс данных, не утверждает findings и не изменяет Production.

От исходной конфигурации к approved knowledge layer

Каждый объект сохраняет связь с источником, версией, индексом и будущим finding.

01 / SOURCE
Source Discovery
Обход CF/EDT, регистрация файлов.

02 / REGISTER
Source ID
Версия и SHA-256 hash.

03 / EXTRACT
Metadata + AST
MDO, BSL, формы, процедуры.

04 / GRAPH
Dependencies
CALLS / READS / WRITES.

05 / CLEAN
DLP
Black → [REDACTED].

06 / CHUNK
Object-aware
1 объект = 1 чанк.

07 / EMBED
Local embedding
Benchmark кандидатов.

08 / INDEX
Hybrid search
Dense + sparse/BM25.

09 / EVAL
Gold Set
Recall@3, MRR.

10 / REVIEW
Approval gate
1С-эксперт / PO.

11 / PUBLISH
Candidate → live
Rollback возможен.

12 / DIFF
Configuration Diff
Только изменённые объекты.

INCREMENTAL MODE

При новой версии конфигурации переобрабатываются изменённые и зависимые объекты, а не весь pipeline.

HYBRID SEARCH

Dense vectors находят смысл, sparse/BM25 — точные PascalCase-имена и технические синонимы.

1 логический объект = 1 неделимый чанк

Retrieval возвращает не «похожий текст», а объект, связи, версию и доказательство происхождения.

Почему не фиксированные 500 символов

Процедуры разрываются, теряется контекст «Документ → Регистр → Модуль», а ссылка на исходный код становится неточной.

Объектный подход

1 процедура = 1 чанк

1 объект метаданных = 1 чанк

Полный контекст зависимостей

Точная ссылка на строки кода

Пример semantic chunk / JSONL

```
{
  "chunk_id": "Document.ЗаявкаНаРасходованиеДС.ObjectModule.ОбработкаПроведения",
  "source_id": "bit_finance_demo_v03",
  "version": "3.2",
  "object_type": "Document",
  "procedure_name": "ОбработкаПроведения",
  "source_file": "src/Documents/.../ObjectModule.bsl",
  "lines": {"start":102,"end":198},
  "relations": {
    "calls": ["CommonModule.Бюджетирование.ПроверитьЛимиты"],
    "writes_to": ["AccumulationRegister.БДДС"],
    "reads_from": ["InformationRegister.ЛимитыБюджета"]
  },
  "content_hash": "sha256:abc123..."
}
```

РЕЗУЛЬТАТ · можно перейти к строкам 102–198, увидеть связи и доказать, что вывод относится к конкретной версии источника.

RAG используется в аудите только после quality gate

Достоверность определяется покрытием, трассировкой, benchmark и экспертной проверкой — не самим векторным поиском.

01 / COVERAGE

Полнота структуры

Реестр исходников сверяется с metadata-пакетом. Неизвлечённое фиксируется как gap pipeline.

02 / GOLD SET

30 контрольных вопросов

Эталонные ответы проверяют релевантные объекты, версии и контекст.

03 / TRACEABILITY

Source → chunk → finding

Source ID, объект, версия, строки, hash и статус review сопровождают вывод.

04 / REVIEW

Ручная приёмка

1С-эксперт или владелец процесса проверяет существенные findings.

100%
объектов покрыто

≥95%
точность чанкинга

100%
DLP coverage секретов

≥85%
Gold Set Recall@3

<10 мин
на 1000 файлов

<2 сек
retrieval response

GOLDEN SCENARIO

```
«Где проверяется лимит БДДС?»
→ Document.ЗаявкаНаРасходованиеДС
→ ОбработкаПроведения · строки 102–198
→ calls / reads / writes + content_hash
```

Gate готовности

Pipeline воспроизводим, approved content индексируется, audit trail сохранён, Golden Scenario пройден. Benchmark embeddings и hybrid search фиксируется до выбора production-профиля.

Что нужно для старта ограниченного ML Engineering PoC

Сейчас требуется разрешение доказать техническую осуществимость — не разрешение промышленного Red-контура.

01 / MVP-A

Синтетическая EDT-выгрузка

Тестовая конфигурация примерно из **50–100 объектов**, Green-источники и synthetic Yellow-like context. Без Red-данных и Production-доступа.

02 / СРЕДА И РОЛИ

Read-only VM и владельцы

VM для ingestion, RAG, журналирования и controlled Gateway. AI/ML-куратор, DevOps, 1С-эксперт и владелец Golden Scenario.

03 / GATE A

Решение по фактам

Pipeline воспроизводим; approved content индексируется; retrieval возвращает metadata; audit trail сохранён; Golden Scenario пройден. Далее — Proceed / Iterate / Narrow / Pause / Stop.

ПРОШУ УТВЕРДИТЬ ограниченный MVP-A для проверки parser-first pipeline на синтетической EDT-выгрузке без Red-данных, Production-доступа и нарушения корпоративных процедур.

Ориентир MVP-A: 8–12 рабочих дней после готовности VM, ролей и тестового набора